

완료보고서

동적객체 경로 예측을 위한 시계열 영상 정보 기반 딥러닝 기술 개발
Development of Deep Learning Technology Based on Temporal
Video Information for Dynamic Object Trajectory Prediction

고려대학교 인공지능학과 김상필 교수

2026. 06

◆ 참여 연구원

구 분	소 속	이 름	이메일	프로젝트 내 역할
PM	현대자동차 자율주행인지개발팀	최종현 책임연구원	chlwhd23@hyundai.com	프로젝트 운영/관리
연구책임자	고려대학교 인공지능학과	김상필 교수	spkim921@gmail.com	과제 총괄 책임 교수
실무책임자	고려대학교 인공지능학과	오경록	dhrudfhr98@korea.ac.kr	Panoptic Occupancy 및 Flow 정보를 안정적으로 예측할 수 있는 딥러닝 기반 네트워크 및 3차원 dense voxel 기반의 Panoptic Occupancy 데이터 GT 생성 등 과제 전반에 대한 기술 개발 참여
참여연구원	고려대학교 인공지능학과	장영동	altu1996@korea.ac.kr	Panoptic Occupancy 및 Flow 정보를 안정적으로 예측할 수 있는 딥러닝 기반 네트워크를 개발
	고려대학교 인공지능학과	김종욱	frankkim1108@korea.ac.kr	실시간 처리 성능을 만족시킬 수 있는 효율적인 딥러닝 네트워크 구조 설계
	고려대학교 인공지능학과	정환희	hwanyo14@korea.ac.kr	실시간 처리 성능을 만족시킬 수 있는 효율적인 딥러닝 네트워크 구조 설계
	고려대학교 인공지능학과	김승현	montm3880@korea.ac.kr	실시간 처리 성능을 만족시킬 수 있는 효율적인 딥러닝 네트워크 구조 설계

◆ 과제 요약서

추진배경 및 목적 (해결방안)	• 기존 객체 탐지 기술은 자율주행이 필요로 하는 연속적인 공간정보를 제공하기에 부족 • 단일 시점 기반 3D Occupancy Map은 정적인 상태만 보여주고, 자율주행환경에서 필요로 하는 동적 정보를 포착하기 어려움 • Voxel 표현 형태의 객체 단위 3D Flow 정보를 담고 있는 학습 데이터 생성 파이프라인 개발 필요 • 인스턴스를 명확히 구분하며, occupancy map을 추론하고 동적 객체의 flow를 예측할 수 있는 효율적인 네트워크 개발 필요 • 해당 기술을 통해 실제 자율주행 시스템의 안정성과 대응 능력을 향상 시킬 수 있을 것으로 기대함
연구내용 (주요 결과)	• Voxel 보다 높은 해상도를 가지는 Point 수준의 flow ground truth 생성을 위한 기술 개발 • Voxel 표현 형태의 객체 단위 3D Flow 정보를 담고 있는 학습 데이터 생성위한 자동화 파이프라인 기술 개발 • 멀티모달 정보 (3차원 포인트 클라우드, RGB 이미지) 를 활용하여 정확한 동적 인스턴스의 구분 기술 개발 • End-to-end 3D Panoptic Occupancy & Flow Forecasting 모델 개발 • 자율주행 플랫폼 (THOR 칩셋 계열 보드) 에서 10 FPS 처리를 목표로 하는 경량 네트워크 구조 개발
주요 결과물	• 소스코드 및 스크립트 일체 (현대자동차 자체 서버 첨부) • AI 분야 Top-tier 학회 논문 3건 (ECCV 2026, NeurIPS 2026) 제출 • 특허 2건 (명세서 작성 및 제출) • 기술보고서 2건 (중간 보고서 및 완료 보고서)
기대효과	• 기존 객체 탐지 중심의 인지 기술을 넘어, 객체 단위의 Occupancy 및 3D Flow 정보를 함께 예측함으로써 자율주행 환경 내 동적 상황 이해 능력을 향상시킬 수 있음. • Point-level Flow GT 및 Dense Voxel 기반 Occupancy/Flow 데이터 생성 파이프라인을 확보하여, 향후 현대자동차 내부 데이터 기반의 고품질 학습 데이터 구축 및 확장에 활용 가능함. • 개발된 데이터 생성 기술, 경량 딥러닝 네트워크, 동적 객체 구분 기술은 향후 Panoptic Occupancy Prediction, Scene Flow Estimation, 경로 예측 등 다양한 자율주행 인지·예측 모듈에 확장 적용 가능함.


목 차

I. 연구 추진 배경	4
II. 주요 연구내용	8
1. 3차원 Dense voxel 기반의 Occupancy 및 Flow 데이터 생성	8
2. Occupancy 및 Flow 예측 경량 딥러닝 네트워크 개발	39
III. 연구추진 이력	54
IV. 평가항목 및 방법	55
V. 연구 결과물	56
VI. 향후 연구방향 제언	57


I. 연구 추진 배경

가. 연구개발 목적 (연구기술의 당면과제 및 애로기술)

- 1) 기존의 객체 탐지 기술 (3D Bbox 등)은 대략적인 영역만을 표기하기 때문에 서로 다른 객체에 대한 **해상력에서 한계**가 존재함.
- 2) 기존 단일 프레임 기반의 3D Occupancy map 생성 방식으로는 동적 장면의 변화를 포착하거나 **미래 예측을 위한 단서**가 부족하다는 한계가 존재함.



“해상력 부족”




“미래 예측을 위한 단서 부족”

I. 연구 추진 배경


가. 연구개발 목적 (연구기술의 당면과제 및 애로기술)

- 이에 따라, 본 연구에서는 객체의 미래 움직임까지 고려한 **3D Panoptic Occupancy Flow** 예측 기술을 개발하고자 하며, 이를 위해 다음의 두 가지 기술 요소에 대한 집중적인 연구개발이 요구됨.



1)데이터 생성 기술 개발

- 실제 자율주행 차량에서 수집 가능한 LiDAR 데이터, SLAM 기반 ego motion 정보, object detection GT 등을 융합하여, **3차원 dense voxel 기반의 panoptic occupancy 데이터** 및 각 객체의 **시계열 flow** 정보를 포함한 고품질 학습 데이터 셋과 그에 대응하는 ground truth를 함께 구축하고자 함.



2)딥러닝 네트워크 개발


- 자율주행 환경에서 발생하는 다양한 동적 상황을 효과적으로 인지하기 위해, **Panoptic Occupancy** 및 **Flow** 정보를 안정적으로 예측할 수 있는 딥러닝 기반 네트워크를 개발하고자 함. 복잡한 장면에서도 높은 정확도와 실시간 처리 성능을 동시에 만족시킬 수 있도록, 효율적인 구조 설계와 학습 기법에 대한 연구를 함께 하고자 함.

I. 연구 추진 배경


나. 본연구를 통한 해결 내용 및 기대효과

- 본 연구는 자율주행 환경에서 발생하는 복잡한 동적 장면을 정밀하게 인지하고, 미래 상황까지 예측할 수 있는 3D **Panoptic Occupancy** 및 **Flow** 예측 기술을 실현하고자 함.
- 이를 위해, 다음 요소에 대한 연구 개발을 통해 기존 기술의 한계를 극복하고자 함.


1) 데이터 생성 기술 개발을 통한 문제 해결 방향



- ① 객체의 움직임을 단순한 3D 박스 수준이 아닌, **복셀 (Voxel)** 단위로 **정밀하게 표현**할 수 있는 학습 데이터를 구축하고자 함.



- ② **Tracking ID** 및 **Trajectory** 정보를 활용하여 최소 1초에서 최대 6초 미래 시점까지 객체 별 **3D Flow** 정보를 생성하는 기술을 개발하고자 함.




- ③ **센서 노이즈**를 보정하고 신뢰도 높은 **voxel occupancy**를 생성하는 고품질 전처리 기술을 개발하여, 학습 데이터의 정확성과 활용도를 크게 향상 시키고자 함.

I. 연구 추진 배경


나. 본연구를 통한 해결 내용 및 기대효과

- 해당 기술 개발을 통해, 기존의 정적인 객체 탐지 중심 인지 방식에서 벗어나, 동적인 환경 변화에 능동적으로 대응할 수 있는 미래형 인지 기술을 확보하게 될 것으로 기대함.
- 궁극적으로는 실제 자율주행 시스템의 안정성과 대응 능력을 크게 향상시킬 수 있을 것으로 기대함.


2) 딥러닝 네트워크 개발을 통한 문제 해결 방향



- ① 자율주행 차량이 주행 중에 주변의 동적 객체들을 개별적으로 인지하고 대응할 수 있도록 **배경과 객체 인스턴스를 명확히 구분**하여 occupancy map을 정확히 추론할 수 있는 **instance-aware 네트워크** 구조를 설계하고자 함.



- ② 정지 객체와 이동 객체를 명확히 구분할 수 있는 occupancy flow 예측 구조를 통해 동적 인지 성능을 강화함.



- ③ 적은 파라미터 수와 연산량으로도 높은 정확도를 유지할 수 있는 **효율적인 네트워크** 구조를 개발하여, 실시간 자율주행 환경에 적합한 인지 기술을 확보하고자 함.

II. 주요 연구내용

3차원 Dense Voxel 기반의 Occupancy 및 Flow 데이터 생성



현대자동차 데이터를 기반으로 3차원 Dense Voxel Panoptic Occupancy와 객체별 시계열 Flow 정보를 포함하는 고품질 학습 데이터베이스 구축

1. LiDAR Panoptic Instance Association
2. 현대자동차 데이터 Dense Occupancy Flow GT 생성 파이프라인
3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발


II. 주요 연구내용

1. LiDAR Panoptic Instance Association

1) Point Cloud 4D Instance Association을 위한 객체 분류 및 매칭 기법 (Geo-4D)


- ① 인스턴스의 전체적인 형태 (Global Geometry)를 고려하는 인스턴스 매칭 기술을 개발하여, 프레임 간 인스턴스의 시간적 일관성을 안정적으로 확보하는 Training-free 4D Panoptic Association 기술 개발
- ② 정적, 동적, 소실 객체를 구분하는 효율적인 매칭 파이프라인을 통해 노이즈한 LiDAR 측정, 예측, 및 소실에 강건한 Point-wise한 대응 관계를 형성 하는 기술을 개발

정적 (Static) 객체




- 중심(center)과 형태(covariance)가 프레임 간 거의 바뀌지 않음

동적 (Dynamic) 객체



- 움직이는 객체는 프레임마다 중심(center)과 형태(covariance)가 변함

소실 (Missing) 객체




- LiDAR는 시야가 가려지면 객체가 일시적으로 몇 프레임동안 사라져 소실됨

II. 주요 연구내용

1. LiDAR Panoptic Instance Association

2) 동적 객체에 대한 Global Geometry-aware Soft Matching (GGSM)

- ① Sinkhorn-Knopp 알고리즘을 통해 나온 transport plan을 correspondence로 취급하여 Iterative Closest Point (ICP) 를 활용한 동적 객체 매칭에 활용함.
- ② 인스턴스의 전체적인 형태 (Global Geometry)를 반영한 대응관계 수립 및 정렬을 수행하고, ICP를 위한 정확한 회전행렬 R , 변환 행렬 t 를 추정함.
- ③ 기존에 최근접 포인트만을 고려하는 Nearest Neighbor 방식은 다대일 매칭이 빈번하게 발생하고, 적절한 대응관계를 추정하지 못하는 문제점이 발생함
- ④ 제안한 Global Geometry-aware Soft Matching 과정을 통해 균일한 매칭 및 포인트간의 대응관계를 효과적으로 추정할 수 있어, 인스턴스의 시간적 일관성을 유지하도록 함.



II. 주요 연구내용

1. LiDAR Panoptic Instance Association

3) 4D Panoptic Instance Association 성능

① 정량적 평가

- 4D Panoptic Segmentation 벤치마크 **SemanticKITTI / nuScenes** 에서 SOTA 성능 달성

#Scan		Validation Set			Test Set		
		$LSTQ(\uparrow)$	$S_{assoc}(\uparrow)$	$S_{assoc}(\uparrow)$	$LSTQ(\uparrow)$	$S_{assoc}(\uparrow)$	$S_{assoc}(\uparrow)$
(a) IoU-based Association							
4D-PLS	4	62.7	65.1	60.5	56.9	56.4	57.4
4D-Stop	4	67.0	74.4	60.3	63.9	69.5	58.8
Eq-4D-Stop	4	70.1	<u>77.6</u>	63.4	67.0	72.0	62.4
Mask4Former	2	70.5	74.3	66.9	<u>68.4</u>	67.3	69.6
(b) Query-propagated Association							
Mask4D	1	<u>71.4</u>	75.4	67.5	64.3	66.4	62.2
(c) Detect & Track Association							
Mask4Former	1	-	-	67.5	-	-	70.5
+ CA-Net	1	70.4	73.4	67.5	66.5	62.8	70.5
+ Geo-4D (Ours)	1	72.7 (+2.3)	78.3 (+4.9)	67.5	70.3 (+3.8)	<u>70.0 (+7.2)</u>	70.5

표. SemanticKITTI 데이터 셋 성능비교

II. 주요 연구내용

1. LiDAR Panoptic Instance Association

3) 4D Panoptic Instance Association 성능

① 정량적 평가

- 4D Panoptic Segmentation 벤치마크 SemanticKITTI / nuScenes 에서 SOTA 성능 달성

	#Scan	$LSTQ$ (↑)	S_{assoc} (↑)	S_{assoc} (↑)	IoU^{St} (↑)	IoU^{Th} (↑)
(a) IoU-based Association						
4D-Stop	4	60.5	62.5	58.6	74.4	54.9
Eq-4D-Stop	4	67.3	73.7	61.5	76.4	58.7
Mask4Former	2	<u>67.6</u>	63.0	72.5	76.6	66.3
(b) Query-propagated Association						
Mask4D	1	58.5	54.1	63.1	75.5	55.7
(c) Detect & Track Association						
Mask4Former	1	-	-	71.0	76.0	65.9
+ CA-Net	1	63.4	56.6	71.0	76.0	65.9
+ Geo-4D (Ours)	1	67.9 (+4.5)	<u>65.0 (+9.4)</u>	71.0	76.0	65.9

표. nuScenes 데이터 셋 성능비교

II. 주요 연구내용

1. LiDAR Panoptic Instance Association

3) 4D Panoptic Instance Association 성능

① 정량적 평가

- LSTQ 72.7 로 기존 방법론 대비 SOTA 수준의 4D Panoptic Segmentation 성능달성
- 학습 기반 temporal association 모듈 없이도 Global Geometry-aware association 방법론을 통해 안정적인 Instance Association수행
- Multi-frame 입력을 사용하는 기존 방법론들 대비 메모리 사용량, 추론시간에 대해서 효율적으로 수행
- 결론 : 높은 tracking 품질을 유지하면서도 더 가볍고 빠른 Instance Association 방법임을 보임.

4D Panoptic Segmentation 성능

72.7 (SOTA)

LSTQ 기준

Memory 사용량 효율

60~70% ↓

RTX A6000 사용 기준

추론 시간 감소율

26~45% ↓

Multi-frame 사용 베이스라인 대비


II. 주요 연구내용

1. LiDAR Panoptic Instance Association

3) 4D Panoptic Instance Association 성능

② 정성적 평가

- 동일 객체의 ID를 안정적으로 유지하는 모습을 여러 도전적인 환경에 걸쳐 보여줌



4D LiDAR Panoptic Segmentation 결과 비교

II. 주요 연구내용

1. LiDAR Panoptic Instance Association

4) Global Geometry-aware Soft Matching 효과

① 정량적 평가

- Point Cloud Registration 벤치마크 **4DMatch-F / 4DLoMatch-F** 에서 기존방법 대비 전체적인 정합 성능 지표 향상
- End-point-Error (EPE) , Outlier와 같은 **전체 정합 성능**을 나타내는 지표에서 높은 성능을 보임
- 수행시간의 약간의 증가만으로 월등한 성능향상을 보이며, **Non-rigid registration** 방식들 대비 월등하게 빠른 속도

Method	4DMatch-F				4DLoMatch-F				Inf. Time
	EPE(↓)	Acc-S(↑)	Acc-R(↑)	Outlier(↓)	EPE(↓)	Acc-S(↑)	Acc-R(↑)	Outlier(↓)	
ICP	0.296	2.96	12.06	71.50	0.565	0.14	0.74	90.87	0.10
Sinkhorn	0.308	2.76	8.13	79.86	0.505	0.20	0.86	89.47	3.76
NICP	0.325	6.44	12.10	80.40	0.517	0.18	0.73	92.37	4.80
NSFP	0.265	8.66	18.65	64.96	0.495	0.38	1.56	84.77	39.54
Ours (ICP+GGSM)	0.210	2.51	11.26	62.58	0.431	0.18	1.19	78.80	1.62

표. Point Cloud Registration 성능 비교


II. 주요 연구내용

1. LiDAR Panoptic Instance Association

4) Global Geometry-aware Soft Matching 효과

① 정성적 평가

- 연속된 프레임에서의 인스턴스의 포인트 대응 관계를 명확하게 정립
- 특히, 강체 (Rigid) 클래스인 자동차, 비강체 (Non-Rigid) 클래스인 사람 클래스에 대해서 모두 포인트 대응관계를 정확하게 설정



Global Geometry-aware Soft Matching (GGSM) 대응관계 시각화

II. 주요 연구내용

2. 현대자동차 데이터 Dense Occupancy Flow GT 생성 파이프라인




문제 : 기존 **3D bounding box** 기반 flow는 객체 내 모든 포인트가 동일한 움직임을 가진다고 가정. 그러나, 실제 주행 환경에서는 객체의 **세부 구조의 변화가 더 복잡하게** 나타나 장면 변화를 충분히 표현하기 어려움



목표 : 현대 자동차 내부 데이터를 활용해 LiDAR 포인트에 대해 **3차원 움직임을 추정**하고, **voxel 단위의 dense occupancy flow GT**를 생성

1 Part 1

Point-wise Flow GT 생성



객체 annotation으로부터 각 LiDAR point의 3D motion vector 생성

2 Part 2


Dense Voxel GT



Dense한 Scene 정보를 voxel 단위 Occupancy로 표현

3 Part 3

Dense Occupancy Flow GT



Dense voxel GT와 flow정보를 결합해 dense occupancy flow 생성

II. 주요 연구내용


2. 현대자동차 데이터 Dense Occupancy Flow GT 생성 파이프라인

현대자동차 데이터 구성

본 데이터 생성 파이프라인은 현대자동차 데이터셋을 사용

Raw Data

- 연속된 LiDAR point cloud



- RGB 카메라 이미지



- Calibration 정보




Extrinsic (LiDAR ↔ Camera)

$$R = \begin{bmatrix} r_{11} & r_{12} & r_{13} & t_x \\ r_{21} & r_{22} & r_{23} & t_y \\ r_{31} & r_{32} & r_{33} & t_z \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

Object-wise Annotations

- 3D bounding box



- 객체 class

Car	Truck	Bus	Pedestrian
			
Cyclist	Motorcycle	Traffic Cone	...
			...


- Instance ID / TrackID



- 객체 동적 / 정적 정보



- 객체 Pose 정보



II. 주요 연구내용

2. 현대자동차 데이터 Dense Occupancy Flow GT 생성 파이프라인


PART 1 - Point-wise Flow GT 생성

Object-aware Point Cloud 생성

🎯 목적 : 각 LiDAR 포인트에 **Semantic / Instance / Motion** 정보를 할당하여 **Object-aware point cloud**로 변환

3D Point Cloud – 3D Bbox 매칭

- 한 시점의 LiDAR point cloud와 3D bounding box 레이블 정보를 사용
- 객체 내부의 각 포인트에 대해 모든 3D bounding box와의 포함 여부를 검사



각 Point에 할당 되는 정보

- 특정 3D Bounding box 내부에 존재하면 해당 object의 annotation 정보를 포인트에 할당
- Raw 데이터인 단순 LiDAR point cloud를 Object-aware point cloud로 변환

각 point에 할당되는 정보

 semantic class · instance/Track ID · state(moving)

 semantic class · instance ID · state(static)

background (box 외부) → annotation 없음

II. 주요 연구내용

2. 현대자동차 데이터 Dense Occupancy Flow GT 생성 파이프라인


PART 1 - Point-wise Flow GT 생성

Point-wise Flow 생성

- 🎯 목적 : 기하학적 정보를 바탕으로 Point-level 대응관계를 파악하고, 객체 내부의 세밀한 움직임을 반영한 Flow 생성

기존 Object-level matching


- 객체 내부 모든 point에 동일한 rigid motion 적용
- 회전, 변형, 부분 가림, 국소적 움직임 등을 표현하지 못함



버스 전체에 동일한 rigid motion 적용
→ 관절부 꺾임 표현 불가

GGSM — Global Geometry-aware Soft matching

- 객체의 기하학적 정보를 기반으로 point-level 대응관계 파악
- 객체 포인트 집합을 확률 분포로 보고 Optimal Transport 활용한 대응관계를 통해 LiDAR 에 강건한 대응관계 수립
- 객체 내부의 불균일한 움직임, 회전, 변형, 부분 가림에도 정밀한 포인트 Flow를 표현



II. 주요 연구내용

2. 현대자동차 데이터 Dense Occupancy Flow GT 생성 파이프라인

PART 1 - Point-wise Flow GT 생성

1 동일 TrackID pair 매칭

현재·다음 시점에서 같은 Track ID 객체 식별

2 같은 좌표계로 정렬

두 시점의 동일 객체를 동일 좌표계로 이동

3 point별 flow 계산


GGSM으로 매칭된 point 쌍의 벡터 계산

Point-wise flow vector 도출

$$\hat{p}_{i,t+1} = T_{obj}(t, t+1) \cdot p_{i,t}$$

$$f_i = \hat{p}_{i,t+1} - p_{i,t}$$

같은 좌표계로 객체를 이동한 뒤 매칭된 point끼리 flow vector를 계산한다.



Moving object의 **정밀 flow vector** → Dense Voxel GT의 입력

II. 주요 연구내용

2. 현대자동차 데이터 Dense Occupancy Flow GT 생성 파이프라인

PART 2 – Dense Voxel GT 생성

동적 / 정적 객체 특성을 고려한 Dense Point Cloud 생성

🎯 목적 : 단일 시점 LiDAR는 **sparse**하고 **occlusion** 문제가 있어, 여러 시점의 포인트를 **누적**해 **dense**한 포인트를 구성

SLAM 기반 다중 시점 포인트 병합


현대차 SLAM 결과로부터 각 시점의 포인트를 world 좌표계로 변환

정적 / 동적 객체 별 point 누적

- ① 정적 객체 : world 좌표 누적
 - 정적 포인트는 SLAM / ego pose를 이용해 world 좌표계로 정합하고 누적함
- ② 동적 객체 : Object frame 누적
 - 같은 track ID를 가진 포인트들을 object frame으로 정렬하여 누적하고, dense object shape을 생성
- ③ 동적 객체 재배치
 - 누적된 dense object shape를 현재 frame의 object pose에 맞춰 다시 배치함


Naive Aggregation (분리 X)

모든 point를 단순 누적 → 동적 객체 motion blur 발생



TRK3D-aware Aggregation (분리 O)

dynamic / static 분리 후 누적 → motion blur 감소



II. 주요 연구내용

2. 현대자동차 데이터 Dense Occupancy Flow GT 생성 파이프라인

PART 2 – Dense Voxel GT 생성

Dense Voxel GT 생성

🎯 목적 : 누적된 dense 포인트 클라우드를 **voxel**로 변환하고 annotation 정보를 부여하여 **dense voxel GT**를 생성

Voxelization

World 좌표의 누적된 dense point cloud 를 voxel grid 로 양자화 (예, 0.2 m, 50 × 50 × 4 m)


Voxel 단위 Annotation 부여

Occupancy, Semantic, Instance 정보 할당

Hole Filling (Optional)

Spare 영역 또는 작은 구멍을 Morphological closing / Poisson Reconstruction을 통해 보강

Dense Voxel GT 생성 결과 예시



0.2 m voxel 해상도의 **dense occupancy** (상) / 대응 카메라 장면 (하)

II. 주요 연구내용

2. 현대자동차 데이터 Dense Occupancy Flow GT 생성 파이프라인


PART 3 – Dense Occupancy Flow GT

Dense Occupancy Flow GT 생성

- 🎯 목적 : Point-wise Flow 데이터와 Dense Voxel GT 정보를 하나로 합쳐 세밀한 장면 표현을 가능하게 하는
Dense Occupancy Flow GT 생성


Voxel-wise Flow Annotation

- GGSM 기반으로 생성한 **Point-wise flow**를 dense voxel grid에 투영
- Occupied voxel 내부 포인트들의 **flow**를 평균하여 **voxel flow** 로 변환
- Occupancy / Semantic / Instance 정보와 함께 최종 **Dense Occupancy Flow GT 구성**



↘ 평균 Flow vector
■ 동적 voxel ■ 정적 voxel

Dense Voxel GT 생성 결과 예시



II. 주요 연구내용

2. 현대자동차 데이터 Dense Occupancy Flow GT 생성 파이프라인

PART 3 – Dense Occupancy Flow GT

Occupancy

voxel 점유 상태

Class

Semantic class

Instance

Track ID

Flow

Voxel 단위 motion vector

Instance center로 향하는 보조 flow가 아니라, point-level motion을
voxel 단위로 변환하여 **실제 scene motion**을 직접 반영

활용 가능성

- 3D Panoptic Occupancy Prediction (HyGE-Occ) 네트워크의 dense supervision 으로 직접 사용
- Voxel Forecasting / Scene Flow estimation 모델의 GT 로 활용 가능
- Planning / Prediction 모듈의 dense 시·공간 표현 입력

II. 주요 연구내용

3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

1) LiDAR-only 동적 레이블링의 한계점


- ① **Sparse Point Cloud** 와 **occlusion** 등으로 인한 동적 객체 분류 오류가 빈번히 발생
- ② 잘못된 Pseudo-label을 통한 **self-supervised scene flow**에 불안정성을 유발하여 학습을 방해

2) RGB-LiDAR 멀티모달 기반 동적 객체 식별 기술 개발


- ① RGB 이미지에서 point tracking을 수행하여 **dense한 시공간 모션 단서**를 추출, Sparse observation 및 occlusion 환경에서도 동적객체를 안정적으로 식별할 수 있는 기술 개발
- ② 추적된 이미지 모션과 ego-motion 기반 움직임을 보상하여 **실제 객체의 독립적인 움직임을 구분**
- ③ 이후 LiDAR 포인트에 다시 대응시켜 **point-level dynamic label**을 정제하는 기술을 개발



(a) Dynamic Ratio vs. Classification Quality



(b) TP/FP Decomposition



II. 주요 연구내용

3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

3) TrackCue 전체 파이프라인

1) Image-based Point Tracking


- ① 초기 동적 객체의 LiDAR 포인트를 RGB 이미지에 투영하고, point tracker (e.g., CoTracker3)를 활용하여 시간적으로 연속된 **2D Motion Trajectory**를 추출

2) Visually Consistent Motion Compensation

- ① 추적된 trajectory와 ego-motion을 기반으로 얻은 rigid trajectory를 비교하여, 차량의 움직임에 의한 motion을 제거

3) Visual Motion Cue Lifting

- ① 이미지 공간의 동적 모션 단서를 LiDAR 포인트에 다시 대응시켜 **point-level dynamic label**을 정제




II. 주요 연구내용

3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

4) RGB & LiDAR Point-level 동적 레이블링 결과

① TrackCue 단계별 시각화

- DUFOMap은 정적 배경이나, 도로 주변 영역까지 동적 포인트로 오검출하는 경향을 보임
- 초기 분류된 동적 포인트를 이미지에 투영한 뒤, **point tracking**을 통해 각 포인트의 **Trajectory**를 추적
- **Visually consistent motion compensation** 방법 을 통해 **ego-motion**으로 인한 움직임을 제거하고 실제 객체의 움직임을 분리 추적
- 정제된 RGB motion cue를 다시 LiDAR 포인트에 대응시켜 더 **정확한 dynamic pseudo label**을 생성




II. 주요 연구내용

3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

4) RGB & LiDAR Point-level 동적 레이블링 결과

② Dynamic Awareness Map 시각화 결과



II. 주요 연구내용

3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

4) RGB & LiDAR Point-level 동적 레이블링 결과

① 정량적 평가

- SeFlow / SeFlow++ 기반의 Auto-labeling 방법에 따른 동적 레이블링 품질 비교
- 기존 DUFOMap 대비 **Precision 27.46%/25.63%, F1-score 15.32%/7.77% 향상** 달성
- 특히, TrackCue는 DUFOMap이 정적 배경을 동적으로 오분류하는 **False Positive (FP)를 크게 줄여** Precision에서 큰 향상 폭을 보임.
- Recall은 일부 감소하지만, 더 **신뢰도 높은 동적 레이블**을 제공하여 F1 Score 및 Dynamic Bucket 성능이 함께 개선

Auto-Labeling Method	Method	Accuracy (%) (↑)	Precision (%) (↑)	Recall (%) (↑)	F1 Score (↑)	Dyn. Bucket (↓)
SeFlow	DUFOMap	82.26	24.62	72.35	36.74	0.373
	TrackCue (Ours)	87.37	31.38	65.22	42.37	0.352
SeFlow++	DUFOMap	91.89	45.07	63.59	52.75	0.328
	TrackCue (Ours)	93.83	56.62	57.09	56.86	0.298

표. 동적 객체 레이블링 기반 Pseudo Ground Truth 품질 비교

II. 주요 연구내용

3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

4) RGB & LiDAR Point-level 동적 레이블링 결과

- ① 정량적 평가
- 다양한 ablation study를 통해 제안한 TrackCue 방식의 효과성과 구성 요소의 기여도를 실증적으로 검증
 - **Point Tracker 선택에 따른 성능 비교** 결과, CoTracker가 F1 score 42.37, Dynamic Bucket 0.352로 가장 **안정적인 성능**을 보임.
 - Image Resolution의 변화에 따른 성능 비교 결과, 해상도가 낮아질수록 **Precision은 증가하지만 Recall과 Dynamic Bucket 성능이 저하**

Metric	Point Tracker			
	DUFOMap	CoTracker3	TAPNext	AllTracker
Accuracy (%) (↑)	82.56	87.37	89.86	86.58
Precision (%) (↑)	24.62	31.38	35.30	30.23
Recall (%) (↑)	72.35	65.22	50.89	67.62
F1 Score (↑)	36.74	42.37	41.68	41.78
Dyn. Bucket (↓)	0.373	0.352	0.423	0.356

표. Tracker에 따른 동적 객체 레이블링 품질 비교

Metric	Image Resolution		
	786x786	512x512	256x256
Accuracy (%) (↑)	87.37	88.55	87.40
Precision (%) (↑)	31.38	32.12	32.78
Recall (%) (↑)	65.22	61.35	57.85
F1 Score (↑)	42.37	42.16	41.85
Dyn. Bucket (↓)	0.352	0.359	0.409

표. 이미지 크기에 따른 동적 객체 레이블링 품질 비교

II. 주요 연구내용

3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

5) Scene Flow Estimation 성능 비교

① 정량적 평가

- 동적 라벨 정제 성능 향상은 downstream task인 Scene Flow Estimation의 성능 향상으로 이어짐
- Argoverse2의 테스트 리더보드 결과로부터 TrackCue를 적용한 모든 baseline에서 성능 향상을 보임
- 특히, Zero-shot 일반화 성능 측면에서도 유의미한 향상을 보임
- Waymo, NuScenes, TruckScenes 등 다양한 데이터셋과 거리 구간에서도 전반적으로 일관된 성능 향상을 보임

Method	Overall		AV2		Waymo		TruckScenes		nuScenes		Aeva	
	Mean	0-35m	0-35m	35-70m	0-35m	35-70m	0-35m	35-70m	0-35m	35-70m	0-35m	35-70m
SeFlow (av2)	0.7367	0.6289	0.3113	0.6638	0.3494	0.7639	0.8885	0.8509	0.7543	1.0514	0.8414	0.8926
+ TrackCue (Ours)	0.7344 (0.23)	0.6286 (0.03)	0.3070 (0.43)	0.6958 (3.20)	0.3234 (2.60)	0.7479 (1.60)	0.8968 (0.83)	0.8675 (1.66)	0.7933 (3.90)	0.9910 (6.04)	0.8227 (1.85)	0.8990 (0.64)
SeFlow++ (av2)	0.7025	0.5919	0.2827	0.6552	0.3192	0.7253	0.8555	0.8473	0.6965	0.9748	0.8057	0.8631
+ TrackCue (Ours)	0.6619 (4.06)	0.5537 (3.82)	0.2781 (0.46)	0.6313 (2.39)	0.3041 (1.51)	0.6339 (9.14)	0.8565 (0.10)	0.7978 (4.95)	0.6550 (4.15)	0.9632 (1.16)	0.6748 (13.09)	0.8238 (3.93)
TeFlow (av2)	0.6125	0.3116	0.2019	0.8826	0.1979	0.8920	0.3884	0.9108	0.3822	0.9848	0.3875	0.8969
+ TrackCue (Ours)	0.6057 (0.68)	0.2987 (1.27)	0.1966 (0.53)	0.8734 (0.92)	0.1870 (1.09)	0.8872 (0.48)	0.3762 (1.22)	0.9123 (0.15)	0.3721 (1.01)	0.9867 (0.19)	0.3619 (2.56)	0.9026 (0.57)

표. Argoverse2 테스트 셋 리더보드 결과


II. 주요 연구내용

3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

5) Scene Flow Estimation 성능 비교

② 정성적 평가

- **TrackCue**는 challenging scenario에서 더 **정확한 flow velocity**를 예측하고, 정적 배경이 동적으로 오분류되어 발생하는 **잘못된 flow prediction**을 효과적으로 억제함
- **Dense RGB motion cue**를 활용하여 LiDAR occupancy 변화만으로 놓치기 쉬운 **큰 객체의 일부 영역까지 안정적으**로 dynamic label을 부여함




II. 주요 연구내용

3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

5) Scene Flow Estimation 성능 비교

② 정성적 평가




II. 주요 연구내용

3. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

5) Scene Flow Estimation 성능 비교

② 정성적 평가

- **TrackCue**는 challenging scenario에서 더 **정확한 flow velocity**를 예측하고, 정적 배경이 동적으로 오분류되어 발생하는 **잘못된 flow prediction**을 효과적으로 억제함
- **Dense RGB motion cue**를 활용하여 LiDAR occupancy 변화만으로 놓치기 쉬운 **큰 객체의 일부 영역까지 안정적으로 dynamic label**을 부여함



Ground Truth



SeFlow



TrackCue (Ours)

II. 주요 연구내용

5. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

- Geo-4D vs. TrackCue 차이

구분	Geo-4D LiDAR Panoptic Instance Association 연구	TrackCue RGB 포인트 트래킹 기반 동적 객체 분리 연구
주요 센서	LiDAR	LiDAR + RGB
핵심 목표	객체 매칭 (Association)	동적 객체 분리 (Separation)
RGB Point Tracking	-	✓ (Dense motion 단서 추출)
전체 기하 구조 반영	✓ (GGSM 제안)	-
동적 라벨 자동 생성	-	✓ (Point-level 라벨 정제)
정답 데이터 (GT) 기여	✓ (Occupancy-Flow GT 토대)	✓ (Annotation 없이 정적 / 동적 라벨 구별)

II. 주요 연구내용

5. RGB 포인트 트래킹 기반 LiDAR 동적 객체 모션 단서 추출 기술 개발

- 두 연구의 역할과 결합

Geo-4D

LiDAR Panoptic Instance Association 연구

인스턴스 시간적 연결

전체 기하 구조 기반 soft matching으로
정적·동적·소실 객체를 안정적으로 연결



TrackCue

RGB 포인트 트래킹 기반 동적 객체 분리 연구

동적 객체 모션 분리

RGB point tracking으로 dense한 motion
단서를 추출해 실제 동적인 객체만 분리



결합 효과 : TrackCue의 RGB 기반 동적 보정으로 정적/동적 분리를 자동화하고 포인트 수준 동적 레이블을 생성
→ 더 정확한 분리와 **Dense Voxel Occupancy / Flow GT 생성**

II. 주요 연구내용

Occupancy Prediction 딥러닝 네트워크 개발

 Panoptic Occupancy 및 Flow 정보를 안정적으로 예측할 수 있는 딥러닝 네트워크 개발. 높은 정확도와 실시간 처리 성능을 동시에 만족시키는 효율적인 구조 설계에 대한 기술 개발


1. HyGE-OCC
2. Occupancy 및 Flow 예측을 위한 경량화

II. 주요 연구내용

6. Occupancy Prediction 딥러닝 네트워크 개발

1) 딥러닝 네트워크 개발 흐름도

- ① 개발 초기에는 Hybrid View-Transformation 기반 Occupancy 생성 기술을 개발
- ② 추후 과제 목표에 맞추기 위해 Flow 및 미래 프레임 예측, 경량화 필요
- ③ 조건을 충족하는 경량 모델을 개발하기 위해 EfficientOCF 모델을 기반으로 개발 착수
- ④ 경량화 및 현대자동차 내부 데이터 실증 수행



II. 주요 연구내용

6. Occupancy Prediction 딥러닝 네트워크 개발

2) 개발 초기 네트워크: HyGE-Occ

- ① LSS와 Gaussian 표현을 결합한 Hybrid BEV 구성
 - **LSS의 local detail**과 **Gaussian branch의 geometric continuity**를 결합하여 정밀하고 연속적인 BEV 표현 생성
- ② Edge Prediction Module 기반 객체 테두리 인식 강화
 - Semantic GT에 Sobel 필터를 적용해 pseudo-edge label을 생성하고, **BEV-level edge probability map**을 함께 학습하여 객체 테두리와 분리 성능을 향상시킴




그림. 두 깊이 표현 BEV 및 hybrid BEV 시각화




그림. Edge Prediction Module 구조도

II. 주요 연구내용

6. Occupancy Prediction 딥러닝 네트워크 개발

3) HyGE-Occ 성능 비교

① 정량적 평가

- **Occ3D-nuScenes** 데이터셋으로 실험 진행
- 평가지표로 **mIoU**, **RayIoU**, **RayPQ**를 사용함
 - **mIoU**: 3D voxel 단위로 semantic class를 맞췄는지 보는 기본 semantic 지표의 평균
 - **RayIoU**: 카메라에서 장면으로 뻗어나가는 ray 단위로 occupancy 정확도를 평가
 - **RayPQ**: RayIoU처럼 ray 기준으로 semantic + instance 예측 정확도 평가

Method	RayIoU	RayIoU _{1m}	RayIoU _{2m}	RayIoU _{4m}	mIoU	FPS
Panoptic-FlashOcc-tiny (1f)	34.8	29.1	35.7	39.7	29.1	45.8
HyGE-Occ-tiny (1f) (Ours)	36.3	30.8	37.2	41.1	29.4	37.7
Panoptic-FlashOcc (1f)	35.2	29.4	36.0	40.1	29.4	41.9
HyGE-Occ (1f) (Ours)	36.8	31.2	37.5	41.6	29.6	33.0
Panoptic-FlashOcc (2f)	36.8	31.2	37.6	41.5	30.3	<u>49.7</u>
HyGE-Occ (2f) (Ours)	37.8	32.2	38.6	42.6	30.4	39.2
Panoptic-FlashOcc (8f)	38.5	32.8	39.3	43.4	31.6	<u>48.1</u>
HyGE-Occ (8f) (Ours)	39.9	34.5	40.7	44.5	32.0	36.8

표. RayIoU 최대 1.6 증가 / mIoU 최대 0.4 증가

Method	RayPQ	RayPQ _{1m}	RayPQ _{2m}	RayPQ _{4m}
SparseOcc (8f)	14.1	10.2	14.5	17.6
Panoptic-FlashOcc-tiny (1f)	12.9	8.8	13.4	16.5
HyGE-Occ-tiny (1f)	14.5	10.5	14.9	18.1
Panoptic-FlashOcc (1f)	13.2	9.2	13.5	16.8
HyGE-Occ (1f)	15.1	11.1	15.5	18.9
Panoptic-FlashOcc (2f)	14.5	10.6	15.0	18.0
HyGE-Occ (2f)	15.8	11.7	16.1	19.5
Panoptic-FlashOcc (8f)	<u>16.0</u>	11.9	16.3	<u>19.7</u>
HyGE-Occ (8f)	17.5	13.1	17.9	21.4

표. RayPQ 최대 1.9 증가

II. 주요 연구내용


6. Occupancy Prediction 딥러닝 네트워크 개발

3) HyGE-Occ 성능 비교


② 정성적 평가

- Occ3D-nuScenes 데이터셋으로 실험 진행
- 베이스라인 모델 대비 더 정확한 객체 테두리 및 Instance 분리가 더 명확함

Camera Input




Panoptic_GT



Panoptic-FlashOcc



HyGE-Occ



Semantic_GT



Panoptic-FlashOcc



HyGE-Occ


그림. 베이스라인 모델과 비교 시각화

II. 주요 연구내용

7. 네트워크 베이스라인 변경

1) 한계 및 확장 필요성

- ① 정성적 동적 장면의 시간적 변화를 직접 예측하지 못함
- ② 미래 occupancy 예측과 flow 예측의 부재로 미래 예측 단서 부족
- ③ 단일 시점 Occupancy map만으로는 향후 planning 단계의 선제 대응이 제한됨
- ④ 따라서 미래 프레임을 포함하여 예측 가능한 베이스라인 모델로 변경



확장 방향

- 현재 프레임과 더불어 미래 프레임을 함께 예측
- IoU, F1과 FPS를 함께 고려하는 경량 모델 설계
- 최종적으로는 end-to-end 4D Occupancy & Flow Forecasting 목표

II. 주요 연구내용

8. Occupancy 및 Flow 예측을 위한 경량 모델 개발

1) 4D Occupancy / Flow Forecasting (EfficientOCF-based)

- ① 6-view RGB images(w/ Camera poses)만을 입력으로 받아 fine-grained 3D occupancy를 예측
- ② 출력으로는 2D BEV occupancy map, height, flow를 예측하며, 전반적인 연산이 2D라는 특성 때문에 height를 별도로 예측
- ③ Flow는 backward flow로, 현재 박셀이 이전 프레임의 차량 중심포인트를 향하는 방향을 예측하며, instance id를 할당하는 데 사용




그림. Height Prediction




그림. Flow Prediction

II. 주요 연구내용

8. Occupancy 및 Flow 예측을 위한 경량 모델 개발

2) 네트워크 경량화 진행

- ① 이미지 Backbone 네트워크를 더 가벼운 구조로 교체
- ② Intermediate channel dimension 축소
- ③ Accuracy-latency trade-off 관점에서 최적 지점 탐색

① 이미지 백본 교체

- 기존 대형 Backbone → 경량 Backbone으로 전환
- 특징 추출 품질을 유지하면서 파라미터 수 및 FLOPs 감소
- 입력 이미지 feature 추출 병목 구간 해소

② 채널 Dimension 축소

- BEV feature 및 intermediate voxel feature의 채널 수 감소
- 행렬 연산량과 메모리 footprint 동시 절감
- 성능 저하 없이 튜닝 완료된 상태

학습 시 VRAM 감소율

57%

70 GB → 30 GB
(RTX Pro6000 × 8 기준)

추론 시간 감소율

50%

90ms → 45ms
(single-frame 기준)

II. 주요 연구내용

8. Occupancy 및 Flow 예측을 위한 경량 모델 개발

3) 모델 성능

- ① GMO(General Movable Object) 정성적 평가
 - **nuScenes** 데이터셋으로 실험 및 테스트 진행
 - BEV 시점에서의 시각화
 - 녹색: Ground Truth overlay
 - 빨간색: Predicted Occupancy map




그림. Scene #1




그림. Scene #2




그림. Scene #3

II. 주요 연구내용

8. Occupancy 및 Flow 예측을 위한 경량 모델 개발

3) Background Occupancy Prediction Head

① GSO (General Static Object) Prediction Head

- 배경 클래스를 예측하기 위해 별도의 GSO head 추가
- Flash-Occ의 Channel2Height 메커니즘을 바탕으로 head 설계
- [512, 512, 40] 중, 높이 40에 대하여 각 픽셀별 occupancy (0, 1) 예측
- 기존 EfficientOCF의 기둥 예측 방식이 아니기 때문에 더욱 정밀한 z축 예측 가능




그림. 3D Voxel Latent Features





그림. Predicted Occupancy

II. 주요 연구내용

8. Occupancy 및 Flow 예측을 위한 경량 모델 개발

3) Background Occupancy Prediction Head

① 정성적 결과

- nuScenes 데이터셋 기준
- 각 클래스별 Occupancy prediction 예측 시각화 결과
- 복셀별 Height map 시각화
- 3차원 복셀 레벨에서의 시각화 결과




그림. Predicted GSO




그림. Height Map





그림. Predicted 3D Occupancy

II. 주요 연구내용

8. Occupancy 및 Flow 예측을 위한 경량 모델 개발

3) Background Occupancy Prediction Head

① 정성적 결과



II. 주요 연구내용

9. 현대차 내부데이터 연동

1) 결과 분석

- ① 성능이 nuScenes에서처럼 동일하게 나오지는 않음
- ② nuScenes 데이터로 학습, 내부 데이터로 추론
- ③ 학습된 nuScenes 데이터와 내부 데이터간의 시야각 차이가 영향을 미칠 수 있음
- ④ 입력 데이터의 Domain gap도 요인이 될 수 있음

* AI로 생성된 예시 이미지



그림. 데이터 시야각 차이




그림. 데이터 도메인 차이


II. 주요 연구내용

9. 현대차 내부데이터 연동


2) 학습 전략

- ① Domain Gap이 가장 큰 요인으로 판단되므로, 추후 내부데이터로 GT를 생성 후 직접 학습하여 도메인을 맞추는 방향을 생각해볼 수 있음
- ② RGB 이미지, 카메라 파라미터, ego pose (내부 데이터 제공)
- ③ Flow & 3D Occupancy Ground Truth (본 과제를 통해 개발된 방법론 활용)

내부 데이터 포함



데이터 생성



II. 주요 연구내용

10. 정량적 목표치 달성도

1) NVIDIA DRIVE Thor 칩셋 vs. NVIDIA RTX Pro6000

- ① 현재 모델 기반으로 약 20 FPS 정도가 나오는 상황
- ② 이를 NVIDIA DRIVE Thor 칩셋 x2 대 기준으로 환산하여 약 12~18 FPS가 나올 것으로 계산
- ③ 10 FPS 이상을 달성해야 하는 목표치 초과 달성

구분	NVIDIA DRIVE Thor	RTX PRO 6000
아키텍처	Blackwell	Blackwell
CUDA 코어 수	2,560	24,064
AI 연산 성능 (FP8)	517 TFLOPS	1,008 FLOPS
AI 연산 성능 (FP16)	258 TFLOPS	500 TFLOPS
메모리 대역폭	~273 GB/s	~1,792 GB/s
FPS	2대 기준 약 12~18 FPS (FP16 최적화 시)	약 20~22 FPS

III. 연구 추진 이력

수행 항목	세부 항목	1	2	3	4	5	6	7	8	9	10	11	12	비고
연구 환경 구축	3D occupancy 기반 end-to-end 네트워크 관련 문헌 조사													
	연구 개발 및 데이터 생성 환경 구축													
3차원 Panoptic Voxel 및 Flow Ground Truth 생성	자체 구축 데이터 수령 및 분석													
	3차원 Panoptic Voxel GT 생성													
	인스턴스별 Flow GT 생성													
중간보고서 작성	중간 결과 정리 및 보고서 작성													
RGB 카메라 기반 Panoptic Occupancy Flow 예측을 위한 경량 딥러닝 모델 개발	입력 데이터에 대한 3차원 공간 구성 및 시계열 데이터 처리를 위한 모듈 구축													
	Panoptic Segmentation 기반 End-to-end 모델 개발													
	자율주행 플랫폼에 적합하도록 네트워크 경량화													
	현대차 내부 데이터 이용 모델 학습 및 성능 평가 비교													
완료보고서 작성	결과 정리 및 보고서 작성													

▲ 최종 모델 시현
및 결과보고 (6/1)

IV. 평가항목 및 방법

	구분	개발 목표	평가방법	달성도 평가				
				부족	일부부족	부분달성	목표달성	초과달성
목표 달성도 자체 평가 결과	정량적 목표	Panoptic Occupancy Prediction & Flow 모델 성능 확보	○ Panoptic Occupancy ○ IoU, mIoU ○ $N_{infer} = 1$	21.72 / 12.73	25.72 / 15.73	29.72 / 18.73	33.72 / 21.73	33.72 이상 / 21.73 이상
			○ Panoptic Occupancy & Flow ○ IoU, F1 ○ $N_{infer} = 3$	18.01 / 33.53	22.01 / 36.53	26.01 / 39.53	30.01 / 42.53	30.01 이상 / 42.53 이상
			○ Panoptic Occupancy & Flow ○ IoU, F1 ○ $N_{infer} = 6$	16.48 / 33.98	20.48 / 36.98	24.48 / 39.98	28.48 / 42.98	28.48 이상 / 42.98 이상
		Panoptic Occupancy Prediction & Flow 모델 실시간성 확보	○ 지정된 하드웨어상 동작 속도 측정 ○ FPS	3 ~ 5	5 ~ 7	7 ~ 10	10	10이상
		• nuScene 데이터셋 기준 Pro6000 GPU로 연산 시 성능 • IoU = 28.50 / F1 = 44.40로 목표치 초과달성 • NVIDIA DRIVE Thor 칩셋 x2 환산 기준 약 12~18 FPS (FP16)						
	정성적 목표	현대자동차 자체 데이터를 활용한 시연 영상						
		• 현대자동차 내부 데이터셋 기준 렌더링 동영상 준비 완료 (소스코드 및 관련 스크립트 일체 제공)						

V. 연구 결과물


연구 결과물	특징 / 성능	비고
중간보고서	3차원 Panoptic Voxel 및 Flow에 대한 Ground Truth 생성 기술 개발 - Panoptic Occupancy Prediction & Flow 모델 구축 - 기존 인지 및 예측 데이터와의 구성 및 로직 비교 / 분석	
최종보고서	- 현대자동차 자체 수집 데이터 기반 3차원 Panoptic Voxel 및 Flow 데이터 생성 - 본 연구에서 개발한 경량 Panoptic Occupancy Prediction & Flow 모델 구현 - 데이터 생성 로직 결과 및 오픈데이터와 비교 분석 결과	
S/W	- PyTorch 기반 모델 소스 코드 - 모델 학습 및 추론 (inference) 을 위한 스크립트 - ReadMe 파일을 통한 사용법 정리 및 관리	
논문	- ECCV 2026 제출 - Training-Free Global Geometric Association for 4D LiDAR Panoptic Segmentation (김상필 교수) - ECCV 2026 제출 - HyGE-Occ: Hybrid View-Transformation with 3D Gaussian and Edge Priors for 3D Panoptic Occupancy Prediction (김상필 교수) - NeurIPS 2026 제출 - Motion Cues from Image-based Point Tracking for LiDAR Scene Flow Estimation (김상필 교수)	총 제출 3건
특허	- 전역 기하 매칭 기술을 이용한 4차원 라이다 파놉틱 분할 개발 기술 – 명세서 제출 3차원 가우시안 및 엣지 사전 정보를 이용한 3차원 파놉틱 점유 예측 방법 및 장치 – 명세서 제출	총 제안 2건

VI. 향후 연구방향 제언

1. 향후 연구방향

1) RGB 이미지 + LiDAR 포인트 클라우드 기반 Self-supervised 학습 기법 제언

- ① 주요 연구내용인 RGB 이미지의 dense motion cue와 LiDAR의 3D geometry 정보를 결합하여 별도의 레이블링 작업 없이 동적 객체에 대한 레이블을 정제하는 방식을 이어, 향후에는 이를 self-supervised 학습 프레임워크로 확장하여 Scene Flow, Occupancy Prediction, 객체 경로 예측 등 다양한 자율주행 인지·예측 태스크에 활용.
- ② RGB 이미지에서 추출한 2D motion trajectory와 LiDAR 기반 3D Flow 간의 motion consistency를 self-supervised loss로 활용하여, 별도의 정답 라벨 없이도 동적 객체의 움직임을 안정적으로 학습하는 LiDAR Flow 학습 기법으로 확장




VI. 향후 연구방향 제언

1. 향후 연구방향

2) 자율주행 월드 모델을 활용한 Occupancy prediction & flow 학습 방식 및 End-to-end 기술 개발

- ① 기존 자율주행 인지 기술은 현재 시점의 객체 위치나 점유 영역 추정에 집중되어 있어, 복잡한 도로 환경에서 동적 객체의 미래 움직임과 장면 변화를 함께 예측하는 데 한계가 존재함.
- ② 실제 자율주행 환경에서는 다양한 객체가 시간에 따라 상호작용하며 움직이므로, 시계열 RGB/LiDAR 정보를 활용해 미래 Occupancy와 Flow를 동시에 예측하는 world model 기반 학습 구조가 필요함.
- ③ 향후에는 시계열 센서 정보를 기반으로 현재 3D Occupancy와 미래 Occupancy 변화, 객체별 Flow를 함께 예측하는 end-to-end 인지·예측 프레임워크로 확장하고자 함.



VI. 향후 연구방향 제언

1. 향후 연구방향

3) 트랜스포머 기반 경량 4D Occupancy forecasting 기술 개발

- ① 기존 4D Occupancy Forecasting 네트워크는 2D BEV 기반 구조로 인해 3D 공간 표현력이 제한적이거나, Full 3D 연산으로 인해 연산량이 커 실시간 적용에 한계가 있음
- ② 기존 트랜스포머 기반 Occupancy 모델은 주로 현재 프레임 예측에 집중하거나, 다수의 voxel query를 사용하여 추론 속도와 메모리 효율성이 낮음
- ③ 향후에는 소수의 instance-wise query를 활용해 객체 단위 occupancy와 motion을 직접 회귀하는 경량 트랜스포머 구조를 개발하여, 낮은 연산량으로 미래 프레임까지 예측하는 4D Occupancy Forecasting 모델을 개발할 예정

